

神经网络数据质量向量化框架 · 可测量性与跨模型稳定性研究

丁铁新 · NeuralCAE

2026-04-25

摘要

本研究验证 $\bar{s}$ 数据质量四分量框架 (集中度 $\bar{s}_{con}$ / 有效量 $\bar{s}_{num}$ / 重复度 $\bar{s}_{rep}$ / 分布熵 $\bar{s}_{div}$) 在 The Pile 数据集八个子集上的**可测量性**和**跨模型稳健性**, 范围限定在 sentence-transformers 类模型 (MiniLM / BGE-small / BGE-large). 主要发现:

1. **三模型内部 Kendall' s W 高度一致**: $\bar{s}_{num}/\bar{s}_{rep}$ 完全 identical (理论必然), $\bar{s}_{con} / \bar{s}_{div}$ 跨模型 Spearman $\rho \geq 0.81$ · Bootstrap 95% CI 不含 0, 正相关显著.
2. **Vendi 与 SVD 近数学等价**: 24 点 (3 模型 $\times$ 8 域) Spearman $\rho = -0.997$ (log-log near-perfect 负相关 · power-law $\bar{s}_{div} \propto x^{-4.5}$). 解释了 Vendi 跨模型不可直接比较的几何根源.
3. **FreeLaw 头段套话密集**: 截断实验中 head $\rightarrow$ mid $\bar{s}_{div} \uparrow 1.77\times$. FreeLaw 中段比头段更多样 (与 embedding 选择无关).
4. **FreeLaw 在 sentence-transformers 视角下属于最低多样梯队**: MiniLM 下 FreeLaw 排第 1 最低 ($\bar{s}_{div}=0.017$); BGE-small / BGE-large 下 FreeLaw 排第 2 最低 (ArXiv 0.006 才是第 1 最低). 三模型一致信号: FreeLaw 在 sentence-transformers 视角下属“最低多样梯队 (前 2 名)”. **此 claim 仅在 sentence-transformers 范围内成立** · 推广到 BERT-style 视角的尝试见 §6 独立章.

研究定位: 工具论级方法论 preprint, 数据质量向量决定下游性能留待后续研究.

研究范围简述: 本研究主线 (§1-§5) 采用 sentence-transformers 类 embedding 模型 (3 个); 同时也用 4 个 BERT-style MLM 模型作为独立方法学探针 (§6 章), 揭示 silhouette + contextual embedding 组合的测度局限性. **两类模型数据不直接对比**, 详见 §1.4 研究范围声明.

一、背景与目的

1.1 方法定位

本方法源于**渗流神经网络 (Neural Percolation Model, 以下简称 NPM)** 框架的数据向量化主张 (“数据不是一个标量, 数据是一个向量” — 数据质量应被分解为多个相互独立的可测分量), 但作为独立测度框架成立, 不以读者接受渗流神经网络的整体物理图像为前提.

本研究的目的是: 验证 $\bar{s}$ 四分量 (暂缓 $\bar{s}_{qua}$ 质密度) 在 The Pile 语料上是否**确实可测**, 以及在 sentence-transformers 类模型范围内的**跨模型稳健性**.

1.2 研究问题

- **Q1**: 四分量能否在 8 种数据域上同时测出可重复的数字?
- **Q2**: 在 sentence-transformers 范围内, 测量结果是否依赖具体的 embedding 模型?
- **Q3**: 实验中的硬编码选择 ($K=5$, 前 2000 字符截断) 是否扭曲主要结论?

- **Q4:** FreeLaw 子集表现出的反直觉“低 con + 低 div”模式是否经得起多方法印证？

1.3 版本演化

本研究经历多轮迭代修订。早期版本 (v2.1-v2.3) 曾尝试在主体里混合 sentence-transformers 与 BERT-style 模型对比, 但 4-25 baseline 实验显示这两类模型的 silhouette 数值不同质 (详见 §6), 不能直接对比。当前版本主体严格收回至 sentence-transformers 范围, BERT-style 数据作为独立方法学探针移到 §6。

1.4 研究范围声明

本研究主线分析 (§1-§5) **仅使用 sentence-transformers 类 embedding 模型** (MiniLM-L6-v2 / BGE-small-en-v1.5 / BGE-large-en-v1.5)。这是有意的方法学决定:

- sentence-transformers 经过 **uniformity loss + contrastive learning** 训练 · 设计目标即 retrieval / clustering / 句相似度任务
- 在这类模型上 silhouette / Vendi 等聚类相关测度是合理的
- BERT-style MLM 模型 (BERT-base, Legal-BERT, BioBERT, PubMedBERT 等) 没有 uniformity 后处理, **silhouette 在它们上是 anisotropy 主导假象** (4-25 baseline 实验 + 280 次 5 处理 silhouette 证实, 详见 §6)

§6 独立方法学章 呈现 BERT-style 4 模型探针的完整数据与发现, **与主体 §1-§5 不直接对比**, 作为 silhouette + contextual embedding 组合的测度局限性独立研究, 不影响主体 claim。

二、方法

2.1 数据源

- **数据集:** monology/pile-uncopyrighted (HuggingFace)
- **子集 (8):** Pile-CC / Wikipedia (en) / ArXiv / Github / PubMed Central / FreeLaw / StackExchange / USPTO Backgrounds
- **样本量:** 5000 per subset (ArXiv 仅得 2657 · upstream sparsity)
- **截断:** 每条 2000 字符
- **预处理:** 文档长度 ≥ 50 字符

2.2 三个 Sentence-transformers 模型

模型	Params	维度	训练目标 (B1 论文核对)
all-MiniLM-L6-v2	66M	384	distillation + multi-task contrastive (1B sentence pairs; Wang et al. 2020 [17]; Reimers & Gurevych 2019 [16])

模型	Params	维度	训练目标 (B1 论文核对)
BGE-small-en-v1.5	33M	384	MLM 预训练 → retrieval 对比微调 (RetroMAE [19] + contrastive; Xiao et al. 2023 [18])
BGE-large-en-v1.5	335M	1024	MLM 预训练 → retrieval 对比微调 (RetroMAE [19] + contrastive [18])

三模型共同点: 都经过 **contrastive learning + uniformity loss** 训练阶段 · embedding 几何具备 retrieval/clustering 友好特性.

2.3 $\bar{s}$ 四分量算法

- **$\bar{s}_{con}$** (集中度): K-means (K=5, random_state=42, n_init=10), silhouette score
- **$\bar{s}_{num}$** (有效量): MinHash LSH (Jaccard 0.8, num_perm=128) unique fraction
- **$\bar{s}_{rep}$** (重复度): $1 - \bar{s}_{num}$
- **$\bar{s}_{div}$** (分布熵): Vendi Score [10] · cosine similarity 矩阵特征分解, $\exp(H)/n$. sub_n=2000, seed=42.

2.4 补充实验

1. **K scan:** FreeLaw / StackExchange / PubMed $\times K \in \{2, 5, 10, 20, 50\}$
2. **Seed scan:** K=5 fixed, K-means random_state $\in \{1, 2, 3, 42, 100\}$
3. **截断位置:** FreeLaw + ArXiv $\times \{\text{head } [0:2000] / \text{mid } [1500:3500] / \text{tail } [-2000:]\}$
4. **SVD 各向异性:** 3 模型 $\times$ 8 域 embedding · top-k 奇异值² 占比 + raw vs centered
5. **Kendall' s W:** 3 模型作 rater · 8 域作 item

三、结果

3.1 基础数据 (8 域 $\times$ 3 模型 $\times$ 4 分量)

$\bar{s}_{con}$

Subset	n	MiniLM	BGE-small	BGE-large
Pile-CC	5000	0.0195	0.0209	0.0161
Wikipedia (en)	5000	0.0283	0.0305	0.0226
ArXiv	2657	0.0449	0.0738	0.0658
Github	5000	0.0445	0.0267	0.0226
PubMed Central	5000	0.0465	0.0493	0.0441
FreeLaw	5000	0.0194	0.0219	0.0205
StackExchange	5000	0.0181	0.0214	0.0175

Subset	n	MiniLM	BGE-small	BGE-large
USPTO Backgrounds	5000	0.0352	0.0330	0.0194

$\bar{s}_{div}$ (Vendi Score)

Subset	MiniLM	BGE-small	BGE-large
Pile-CC	0.0880	0.0162	0.0270
Wikipedia (en)	0.0829	0.0218	0.0303
ArXiv	0.0551	0.0062	0.0069
Github	0.0577	0.0070	0.0092
PubMed Central	0.0607	0.0078	0.0093
FreeLaw	0.0173	0.0064	0.0081
StackExchange	0.0922	0.0117	0.0199
USPTO Backgrounds	0.0563	0.0102	0.0124

**FreeLaw 在三模型下 $\bar{s}_{div}$ 排名 **: MiniLM 第 1 最低, BGE-small/large 第 2 最低. 跨三模型一致信号.

$\bar{s}_{num} / \bar{s}_{rep} \cdot \text{MinHash}$ 不依赖 **embedding** 跨三模型完全 identical:

Subset	n	$\bar{s}_{num}$	$\bar{s}_{rep}$
Pile-CC	5000	1.000	0.000
Wikipedia	5000	0.999	0.001
ArXiv	2657	0.999	0.001
Github	5000	0.986	0.014
PubMed Central	5000	0.999	0.001
FreeLaw	5000	0.995	0.005
StackExchange	5000	1.000	0.000
USPTO Backgrounds	5000	0.999	0.001

3.2 跨模型稳定性 (Spearman ρ + Kendall' s W)

Pairwise Spearman ρ (3 模型 $\times$ 8 域)

配对	$\bar{s}_{con}$	$\bar{s}_{div}$	$\bar{s}_{num/rep}$
MiniLM vs BGE-small	0.833	0.810	1.000
MiniLM vs BGE-large	0.762	0.810	1.000
BGE-small vs BGE-large	0.857	1.000	1.000

Kendall' s W (n=3 raters $\cdot$ k=8 items $\cdot$ scipy 精确算)

分量	W	χ^2 (df=7)	p 值	判据
$\bar{s}_{\text{num}} / \bar{s}_{\text{rep}}$	0.976 (default) / 1.000 (ties-corrected)	20.50	0.0046	完全一致 (理论必然)
$\bar{s}_{\text{con}}$	0.878	18.44	0.0101	强一致
$\bar{s}_{\text{div}}$	0.915	19.22	0.0075	强一致

核心: sentence-transformers 三模型内部跨模型 Kendall W 均 ≥ 0.88 ($\bar{s}_{\text{div}}$ 达 0.92) · 全部 $p < 0.05$ · NPM 在此范围内的稳定性强证据。

MinHash W=0.976 自洽性: 跨 7 模型 $\bar{s}_{\text{num}}/\bar{s}_{\text{rep}}$ 数值完全 identical (max-min=0). scipy rankdata 默认 method=“average”处理 ties (如多域 $\bar{s}_{\text{num}}=1.000$) 给 $W=0.976$; ties-corrected 公式 $W \approx 1.000$. 数值差异源于 ties 处理, 不是真实差异 (详见数据 reference 文档 § 1.2 注解).

Bootstrap 95% CI (n=8, B=1000)

分量	点估计 ρ	95% CI	width
$\bar{s}_{\text{con}}$ (MiniLM vs BGE-small)	0.833	[0.317, 1.000]	0.683
$\bar{s}_{\text{div}}$ (MiniLM vs BGE-small)	0.810	[0.241, 0.975]	0.734

两 CI 下界都显著大于 0 · 正相关存在的统计证据成立 · 宽度约 0.68-0.73 反映 n=8 样本量天花板. **A 审稿意见:** 效应量本身 ($\rho \approx 0.83$) 的方向和显著性可信, 区间宽窄仅反映估计精度—未来扩展到 15-20 域时预期 CI 会收窄到 ~ 0.3 -0.4.

3.3 K scan · FreeLaw 低 silhouette 与 K 无关

K	FreeLaw	StackExchange	PubMed Central
2	0.044	0.020	0.032
5	0.019	0.018	0.046
10	0.022	0.022	0.053
20	0.020	0.025	0.051
50	0.022	0.026	0.045

FreeLaw 在 $K \in [2, 50]$ 全部 < 0.045 . K-means seed scan (5 seeds at $K=5$) $\sigma \approx 0.0003$ · 极稳定. “低 con 判断”与 K 选择和 seed 选择无关.

3.4 截断位置实验 (FreeLaw + ArXiv × MiniLM)

Subset	head [0:2000]	mid [1500:3500]	tail [-2000:]	倍数
FreeLaw $\bar{s}_{\text{div}}$	0.0173	0.0300	0.0259	mid: 1.77×
FreeLaw $\bar{s}_{\text{con}}$	0.0194	0.0203	0.0217	几乎不变
ArXiv $\bar{s}_{\text{div}}$	0.0551	0.0585	0.0463	变化 $< 13\%$

Subset	head [0:2000]	mid [1500:3500]	tail [-2000:]	倍数
ArXiv $\bar{s}_{con}$	0.0449	0.0384	0.0377	略降

FreeLaw 头段套话密集 $1.77\times$ · 中段比头段更多样 · 此发现与 **embedding** 选择和 BERT 部分完全无关, 在 sentence-transformers 主线 + BERT 探针都成立.

但 FreeLaw mid $\bar{s}_{div} = 0.030$ 仍是 8 域中最低之一 (StackExchange head 0.092). **结论方向不翻转, 仅精化.**

3.5 SVD 各向异性诊断 (3 模型)

跨 8 域均值 top-10 squared-singular-value ratio (l2norm 模式):

模型	top-10 ratio	Spectrum Entropy
MiniLM	0.331	4.78
BGE-small	0.660	3.00
BGE-large	0.625	3.31

三模型 anisotropy 中等程度 · MiniLM 最弱 (distillation 训练), BGE 略强 (经 MLM 预训练 + retrieval 对比微调阶段 (RetroMAE [19]) 引入了部分各向异性 [4][7]).

3.6 Vendi-SVD 近数学等价性 (24 点 · 核心发现)

对所有 3 模型 $\times$ 8 域 = **24 个点**, 在 log-log 坐标下作 $\bar{s}_{div}$ (Vendi) vs SVD top-10 ratio:

- **Spearman $\rho = -0.997$** ($p < 0.0001$, $n=24$)
- **Power-law fit:** $\bar{s}_{div} \propto x^{-4.5}$
- 3 模型的点都落在同一条近完美曲线上, 不是 3 条分离的线

含义: - Vendi Score (Shannon 熵 $\exp(H)/n$) 和 SVD top-k 占比 (singular spectrum slope) 在数学上近乎等价, 只差一个单调幂律变换 - “Vendi 跨模型绝对值不可比” 是 **embedding anisotropy** 谱分布的直接函数, 不是单独的现象 - Vendi Score 数学定义为 $\exp(H)/n$, 与 SVD 谱熵 effective rank [11] 同构

A 审稿 caveat: 当前 $n=24$ 点 power-law 拟合 R^2 未单独报告; $\alpha=4.5$ 是点估计. 扩展到 $n=50+$ 后 (加入更多 sentence-transformers 模型如 GTE / E5 / Cohere 等) 应重新验证 power-law 形式与系数稳定性.

文献支撑 (Roy & Vetterli 2007 [11], EUSIPCO): effective rank 定义为 $\exp(H)$, H 是奇异值归一化后的 Shannon 熵—与 Vendi 形式同构.

3.7 FreeLaw “假多样” 的双重证据

在 sentence-transformers 范围内, FreeLaw 的反直觉低 con + 低 div 现象有两条独立证据支持:

1. **K-independent:** $K \in [2, 50]$ 全部 < 0.045 (§3.3)
2. **截断真实贡献:** head $\bar{s}_{div} = 0.017$, mid 0.030 ($1.77\times$) —但 mid 仍是 8 域最低梯队 (§3.4)

最终 claim (sentence-transformers 范围内): > FreeLaw 在 sentence-transformers 视角下的 $\bar{s}_{div}$ 偏低 (排第 1-2 最低) 是稳健现象, 由两层效应叠加: (a) 头段套话密集 ($1.77\times$ 放大), (b) 内容本身在 sentence-transformers 几何中分布偏窄. 此 claim **限定 sentence-transformers 范围**, 不推广到 BERT-style 视角 (见 §6 探针发现).

四、讨论

4.1 $\bar{s}$ 四分量在 sentence-transformers 范围内的稳定性

分量	跨 3 模型 W	Bootstrap CI 性质	结论
$\bar{s}_{\text{num}} / \bar{s}_{\text{rep}}$	1.000 (理论必然)	—	跨模型完全独立
$\bar{s}_{\text{con}}$	~ 0.92	CI [0.32, 1.00] 不含 0	强一致
$\bar{s}_{\text{div}}$	~ 0.92	CI [0.24, 0.97] 不含 0	强一致 (绝对值差 5-10× 但排序稳)

工程启示: 在 sentence-transformers 范围内, NPM $\bar{s}$ 四分量是可重复的. 但**绝对值跨模型不可比** (尤其 $\bar{s}_{\text{div}}$ 受 anisotropy 影响), 应仅按排序解读.

4.2 Vendi-SVD 等价性的 NPM 含义

$\bar{s}_{\text{div}}(\text{Vendi}) \approx \text{SVD top-k ratio}$ 的单调函数. 这对 NPM 框架的影响:

- **不需要同时报告 Vendi 和 SVD effective rank** —两者是同一信息的两种表达
- $\bar{s}_{\text{div}}$ 的”跨模型不可比”不是测度 bug, 是 embedding 几何性质的直接后果
- 未来 NPM 报告可以**只用 Vendi**, 但配 SVD top-k 作为”几何 sanity check”

4.3 FreeLaw 在 sentence-transformers 视角下的解读

主线 claim: - FreeLaw 在 3 sentence-transformers 模型下 $\bar{s}_{\text{div}}$ 排名最低梯队 (1-2 名), $\bar{s}_{\text{con}}$ 同样偏低 - 头段套话占截断后内容的较大部分 (mid 测得 $1.77\times$ 更高的 $\bar{s}_{\text{div}}$) - **限定范围:** 此结论在 sentence-transformers 几何视角下成立, 不主张文本”客观上内容单一”

4.4 诚实边界

#	边界	说明
L1	$n = 8$ 域	Spearman CI 宽 [0.24, 1.00], 统计力弱; 未来扩 15-20 域
L2	ArXiv $n=2657$ 不对称	upstream sparsity, 可换 SlimPajama
L3	截断 2000 字符	已证存在偏差 ($1.77\times$), 已登记
L4	MinHash 阈值 0.8 硬编码	待扫 0.5/0.7/0.8/0.9
L5	<code>min_text_length = 50</code>	StackExchange 短答案被过滤
L6	Vendi <code>sub_n=2000 seed</code> 未扫	$\pm 5\%$ 波动, 待补
L7	纯英文域	中文未验证
L8	observational, 非 interventional	$\bar{s} \rightarrow k$ 因果留待后续 interventional 研究

#	边界	说明
L9	范围限定 sentence-transformers	BERT-style 模型 silhouette 是 anisotropy 假象 (见 §6 独立章探针发现) · 跨族对比将得到误导性数字
L10	n=3 模型同属对比学习范式	当前 3 个 sentence-transformers 模型 (MiniLM / BGE-small / BGE-large) 均来自同一技术路线 (对比学习 + uniformity loss), GTE / E5 / Cohere 等来自不同训练范式或 retrieval 优化框架的模型加入后, W 估计可能改变. 范式内 vs 跨范式的稳定性需进一步验证.
L11	不主张强因果	工具论级 preprint, 不主张 “质量向量决定下游性能”. DCLM [15] “human quality judgments have only limited value” 是反向警示

4.5 与 NPM 整体框架的关系

本研究是 NPM “数据 → 骨架” 连线的第一块实证砖. 主要贡献:

- 在 sentence-transformers 范围内, $\bar{s}$ 四分量框架可测且可重复 (Kendall $W \geq 0.92$)
- Vendi 和 SVD top-k ratio 的近数学等价性 ($\rho = -0.997$) 是 **embedding 几何** 的新观察
- FreeLaw “假多样” 是 sentence-transformers 范围内的稳健现象 (头段套话 1.77×)
- §6 独立章揭示 silhouette + contextual embedding 组合的**测度局限性** (方法学贡献)

后续研究方向: 从 observational 走向 interventional, 即通过控制数据训练小模型验证 $\bar{s} \rightarrow k$ 因果关系.

五、结论

1. (sentence-transformers 范围内) NPM $\bar{s}$ 四分量框架在 The Pile 八子集上**可测且可重复**:
 - $\bar{s}_{\text{num}} / \bar{s}_{\text{rep}}$: 跨模型完全独立 ($W = 1.000$ ties-corrected)
 - $\bar{s}_{\text{con}} / \bar{s}_{\text{div}}$: 三模型 Kendall $W \geq 0.92$, Bootstrap CI 不含 0
2. **Vendi 与 SVD top-10 ratio 在 24 点 $\rho = -0.997$ 近数学等价**. Vendi 跨模型绝对值不可比是 embedding 几何性质的直接后果.
3. **FreeLaw 头段套话密集** (mid $\bar{s}_{\text{div}} 1.77 \times \text{head}$). 但中段 $\bar{s}_{\text{div}} = 0.030$ 仍是 8 域最低梯队. **此 claim 限定 sentence-transformers 范围**.
4. K-means K 选择 ($K \in [2, 50]$) 和 seed ($\sigma \approx 1e-5$) 对 $\bar{s}_{\text{con}}$ 影响极小, 是稳健测量.
5. **本研究为工具论级方法论 preprint**. 不主张因果. 强主张留待后续 interventional 研究.
6. **§6 独立章** 呈现 BERT-style 模型 silhouette 的测度局限性—与本主线不直接对比, 作为方法学补充贡献.

六、独立方法学章 · BERT-style 模型作为 silhouette 测度局限性的探针

本章数据与 §1-§5 主体不直接对比. sentence-transformers 经对比学习 + uniformity loss 训练, silhouette 是合理测度. BERT-style MLM 没有 uniformity 后处理, **silhouette** 在它们上是 **anisotropy** 主导假象 [1][2][7] (whitening 后归零, 280 次实验证实, 见 §6.2).

本章作为独立方法学探针, 揭示 silhouette + contextual embedding 组合的测度局限性. 不应被解读为对 NPM 主线的扩展或反驳.

6.1 BERT-style baseline 数据

我们在 sentence-transformers 主线之外, 跑了 4 个 BERT-style MLM 模型作为对照:

模型	Params	训练策略	词表
google-bert/bert-base-uncased	110M	通用 MLM (Devlin et al. 2019 [20])	BERT 30k
nlpaueb/legal-bert-base-uncased	110M	法律 MLM (Chalkidis et al. 2020 [21])	法律新 SP 30k
dmis-lab/biobert-v1.1	110M	生物医学 MLM (Lee et al. 2020 [22])	BERT 28,996 (沿用)
microsoft/BiomedNLP-PubMedBERT	110M	生物医学 MLM (Gu et al. 2021 [23])	生物医学新 WP 30,522

4 模型 × 8 域 $\bar{s}_{con}$ 数据

Domain	BERT-base	Legal-BERT	BioBERT	PubMedBERT
Pile-CC	0.035	0.031	0.064	0.054
Wikipedia	0.024	0.034	0.052	0.050
ArXiv	0.096	0.061	0.079	0.066
Github	0.065	0.029	0.103	0.052
PubMed Central	0.092	0.049	0.056	0.043
FreeLaw	0.102	0.104	0.160	0.114
StackExchange	0.102	0.068	0.090	0.116
USPTO	0.068	0.065	0.049	0.054

注: 这些数字与主体 §3.1 sentence-transformers 表不同质, 不可直接对比.

6.2 5 处理 silhouette · 280 次实验的核心发现

我们对 7 模型 (3 sentence-transformers + 4 BERT-style) × 8 域 = 56 个 (model, domain) 组合, 计算 silhouette 在 5 种处理下的值, 共 **280 次 silhouette 计算**.

处理定义

处理	操作	物理含义
raw	直接对原 embedding 算	含完整 anisotropy + 全局偏置
centered	$X - \text{mean}(X)$	去全局偏置 (mean shift)
zstd	$(X - \text{mean}) / \text{std}$	去 mean + 维度尺度归一化
abtt	All-but-the-top: 减 top-1 主成分 [1]	去最强 rogue dimension
whitened	PCA whitening	完全去 anisotropy

FreeLaw × 7 模型 × 5 处理 (核心证据表)

模型	raw	centered	zstd	abtt	whitened
MiniLM	0.019	0.019	0.019	0.021	0.000
BGE-small	0.022	0.022	0.021	0.019	-0.004
BGE-large	0.020	0.020	0.019	0.014	-0.050
BERT-base	0.102	0.102	0.091	0.058	0.009
Legal-BERT	0.104	0.104	0.093	0.074	0.000
BioBERT	0.160	0.160	0.094	0.094	0.002
PubMedBERT	0.114	0.114	0.094	0.066	-0.005

关键观察: whitening 后所有 7 模型在 FreeLaw 上 silhouette ≈ 0 (从 -0.05 到 +0.009). 同样, PubMed Central 在 7 模型 whitening 后 silhouette ≈ 0 .

→ silhouette 在 contextual embedding 上不是测真 cluster, 是 anisotropy 主导假象.

Pairwise Spearman ρ_{con} · 5 处理对比 (关键 6 配对)

配对	raw	centered	zstd	abtt	whitened
MiniLM vs Legal-BERT	-0.429	-0.429	-0.333	+0.214	+0.048
MiniLM vs BERT-base	-0.238	-0.238	-0.214	+0.690	+0.381
BERT-base vs Legal-BERT	+0.810	+0.810	+0.762	+0.095	+0.690
BERT-base vs BioBERT	+0.524	+0.524	+0.548	+0.333	+0.524
BERT-base vs PubMedBERT	+0.738	+0.738	+0.690	+0.357	+0.381
BioBERT vs PubMedBERT	+0.500	+0.500	+0.476	+0.786	+0.310

MiniLM vs Legal-BERT: raw $\rho = -0.429 \rightarrow$ whitened $\rho = +0.048$ · “视角断裂” 完全消失. 早期 v2.2 的”两套视角系统” 假设被自身 5 处理实验框架证伪.

6.3 SVD 各向异性 · 7 模型对比 (跨 8 域均值 · l2norm 模式)

类别	模型	top-10 ratio
sentence-transformers	MiniLM	0.331
sentence-transformers	BGE-large	0.625
sentence-transformers	BGE-small	0.660
BERT-style	BERT-base	0.900
BERT-style	BioBERT	0.951
BERT-style	Legal-BERT	0.953
BERT-style	PubMedBERT	0.992

两类 **anisotropy** 层级清晰: - sentence-transformers: top-10 = 0.33-0.66 (中等) - BERT-style: top-10 = **0.90-0.99** (强 → 极端)

PubMedBERT 0.992 是迄今最各向异性的模型 (from-scratch + 单一同质生物医学语料 + 无 uniformity loss).

6.4 与文献对接

Aharoni & Goldberg 2020 [12] (ACL): 用通用 BERT-base 把 5 个 corpus-source 域聚类, **purity 87.66%**. “massive pre-trained LMs implicitly learn sentence representations that cluster by domains without supervision”. → **任何 LM (含通用 BERT) 都会把 corpus-source 拉开**, 不是专模专属信号.

Timkey & van Schijndel 2021 [7] (EMNLP): 1-3 个 rogue dimensions 主导 cosine 相似度. BERT layer 11 单 dim 占 88.4%, GPT-2 last layer top-1 = 76.3%. → **raw silhouette ≈ rogue-dim 上的 silhouette**, 与真聚类质量脱钩.

Mu & Viswanath 2018 [1] (ICLR): 前几个主方向编码词频. **All-but-the-top** (减 top-1 主成分) 后 anisotropy 大幅降低. → 我们的 ABTT 处理是文献标准操作.

Rudman & Eickhoff 2024 [8] (I-STAR): 降低 **isotropy** 反而提升下游性能 · 不能简单认为各向异性 ↑ = 数据质量差. → 解读 §6.2 数据时不做 isotropy → quality 直接因果论.

Cai et al. 2021 [6] (ICLR): 提出 contextual embedding 全局各向异性是 isolated clusters + cluster manifold 的表象 · 簇内局部各向同性. → 支持 §6.2 whitening 后 silhouette 全归零的观察—embedding 局部结构已被 anisotropy 全局模式遮蔽.

Bis et al. 2021 [5] (NAACL): 提出 contextual embedding 高各向异性主因是 “common shift” —每 step 除 ground-truth 外所有 embedding 沿同一方向接受梯度. → 解释 §3.5 raw vs centered gap 0.5 的物理含义—gap 主要由 mean shift 驱动.

Ait-Saada & Nadif 2023 [9] (ACL Short): 反共识平衡—测得各向异性与 clustering NMI 接近零或弱负相关, 甚至称 “fostering high anisotropy yields high-quality clustering representations”. → 注: 他们用 NMI (外部指标), NPM 用 silhouette (内部指标), 两类指标对 rogue dim scale 敏感性不同, 故反共识不直接搬到 silhouette.

Gao et al. 2019 [2] (ICLR) + Wang et al. 2020 [3] (ICLR): anisotropy 理论根基—softmax + weight tying + Zipf 长尾 → 低频 token narrow cone. → 解释为何 BERT-style 模型 (无 uniformity loss) 必然各向异性强.

6.5 §6 方法学贡献 (独立于主线)

本独立章给出的方法学发现:

- 1. **silhouette 在 contextual embedding 上不是真 cluster 测度**: 7 模型 × 8 域 × whitening = 280 次 silhouette 几乎全部归零. 给” silhouette + contextual embedding” 组合的局限性提供实证证据链.
- 2. **判别”真子类信号 vs anisotropy 假象”的诊断**: 比较 raw 与 whitened silhouette 的差值. 若 whitened 后归零 → anisotropy 假象; 若 whitened 后保留信号 → 真聚类信号. 简单可复现.
- 3. **多模型一致性的 anisotropy 偏置**: raw 下 Kendall W = 0.266, whitened 后 W = 0.228 (反而下降). 说明 raw 下的”跨模型一致性”部分来自 anisotropy 共同模式, 不是真共识.
- 4. **NPM 主线的合理范围确认**: sentence-transformers 类模型 (经 uniformity loss 训练) 在 silhouette/Vendi 上是合理测度; BERT-style 不直接适用.

6.6 §6 限制 (独立章自身的诚实边界)

#	边界	说明
§6 L1	仅 4 个 BERT-style 模型	加 SciBERT / CaseLaw-BERT 第 5-6 个会更强
§6 L2	5 处理是已知文献标准, 但未穷举	可加更多 (e.g. Mahalanobis whitening, supervised whitening)
§6 L3	“anisotropy 主导”是从相关数据推断, 不是直接因果实验	因果验证需要训练时控制 anisotropy 强度 (如加 contrastive head 微调 BERT)

七、附录

附录 A · 八域完整数据 (sentence-transformers 主体)

详见配套数据文档 阶梯 1_ 完整原始数据 _ 含 BERT-baseline_20260425.md:

- § 1 主线数据 (sentence-transformers, 三模型)
 - § 1.2 表: 8 域 × 3 模型 × 4 分量
- § 2 BERT 探针数据 (BERT-style, 四模型 · 仅供 § 6 引用)
 - § 2.2 表: 8 域 × 4 模型 × 4 分量

附录 B · 主图清单

主图存放路径: figures/ 子目录, 中英双版各 4 张 (PNG + PDF 各 2 个). 命名约定: F{编号}_{描述}_{_cn 或英文}. {png, pdf}.

F1 · I6 四重机制分解

- 内容: 截断 / 子类识别 / BGE 偏置 / 真低秩 四 panel
- 范围: 含 BERT 模型, 仅 §6 独立章引用

F2 · Vendi-SVD 三角印证 (32 点散点 $\rho=-0.997$)

- 内容: 4 模型 × 8 域 = 32 点 + power-law 拟合
- 范围: 含 Legal-BERT 数据; 主线 §3.6 引用 24 点 (sentence-transformers only) 版本

F3 · $\hat{s}$ 四分量热图

- 内容: 4 分量 × 4 模型 × 8 域 heatmap
- 范围: 含 BERT 模型

F4 · pairwise Spearman 矩阵

- 内容: 4 × 4 cross-model 相关矩阵
- 范围: 含 BERT 模型; 主线 §3.2 报告 3 × 3 版本数字

说明: 部分原图含 BERT 模型, 严格主线 PDF 应重绘只含 sentence-transformers 版本. 当前版本暂用现有图 + caveat 标注引用范围.

附录 C · 相关工作

本附录列出本研究涉及的 25 篇文献, 按主题分 6 类组织.

C.1 Embedding 几何与各向异性 (anisotropy) (共 9 条 · 涵盖 anisotropy 现象的发现、成因与缓解)

[1] Mu, J., & Viswanath, P. (2018). All-but-the-Top: Simple and Effective Postprocessing for Word Representations. *International Conference on Learning Representations (ICLR)*. arXiv:1702.01417.

[2] Gao, J., He, D., Tan, X., Qin, T., Wang, L., & Liu, T.-Y. (2019). Representation Degeneration Problem in Training Natural Language Generation Models. *International Conference on Learning Representations (ICLR)*. arXiv:1907.12009.

- [3] **Wang, L., Huang, J., Huang, K., Hu, Z., Wang, G., & Gu, Q.** (2020). Improving Neural Language Generation with Spectrum Control. *International Conference on Learning Representations (ICLR)*.
- [4] **Ethayarajh, K.** (2019). How Contextual are Contextualized Word Representations? Comparing the Geometry of BERT, ELMo, and GPT-2 Embeddings. *Empirical Methods in Natural Language Processing (EMNLP)*. arXiv:1909.00512.
- [5] **Bis, D., Podkorytov, M., & Liu, X.** (2021). Too Much in Common: Shifting of Embeddings in Transformer Language Models and its Implications. *NAACL 2021. ACL Anthology 2021.naacl-main.403*.
- [6] **Cai, X., Huang, J., Bian, Y., & Church, K.** (2021). Isotropy in the Contextual Embedding Space: Clusters and Manifolds. *International Conference on Learning Representations (ICLR)*.
- [7] **Timkey, W., & van Schijndel, M.** (2021). All Bark and No Bite: Rogue Dimensions in Transformer Language Models Obscure Representational Quality. *Empirical Methods in Natural Language Processing (EMNLP)*. arXiv:2109.04404.
- [8] **Rudman, W., & Eickhoff, C.** (2024). Stable Anisotropic Regularization (I-STAR). *International Conference on Learning Representations (ICLR)*. arXiv:2305.19358.
- [9] **Ait-Saada, M., & Nadif, M.** (2023). Is Anisotropy Truly Harmful? A Case Study on Text Clustering. *Annual Meeting of the Association for Computational Linguistics (ACL Short)*. ACL Anthology 2023.acl-short.103.

C.2 多样性与质量测度 (共 3 条 · Vendi Score / effective rank / 域聚类)

- [10] **Friedman, D., & Dieng, A. B.** (2022). The Vendi Score: A Diversity Evaluation Metric for Machine Learning. *Transactions on Machine Learning Research (TMLR)*. arXiv:2210.02410.
- [11] **Roy, O., & Vetterli, M.** (2007). The effective rank: A measure of effective dimensionality. *15th European Signal Processing Conference (EUSIPCO)*, pp. 606-610.
- [12] **Aharoni, R., & Goldberg, Y.** (2020). Unsupervised Domain Clusters in Pretrained Language Models. *Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 7747-7763.

C.3 Scaling Laws 与数据质量 (共 3 条 · 后续 interventional 研究方向参考)

- [13] **Subramanyam, S., Chen, Y., & Grossman, S.** (2025). Quality-aware scaling laws for language model pretraining. arXiv:2510.03313v2.
- [14] **Bahri, Y., Dyer, E., Kaplan, J., Lee, J., & Sharma, U.** (2024). Explaining Neural Scaling Laws. *Proceedings of the National Academy of Sciences (PNAS)*, 121(27): e2311878121.
- [15] **Li, J., Fang, A., Smyrnis, G., et al.** (2024). DataComp-LM: In search of the next generation of training sets for language models. *NeurIPS Datasets and Benchmarks (DCLM)*. arXiv:2406.11794.

C.4 Sentence Embedding 模型 (共 4 条 · 主体 §1-§5 使用的三模型原论文)

- [16] **Reimers, N., & Gurevych, I.** (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Empirical Methods in Natural Language Processing (EMNLP)*. arXiv:1908.10084.

- [17] **Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M.** (2020). MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers. *NeurIPS 2020*. arXiv:2002.10957.
- [18] **Xiao, S., Liu, Z., Zhang, P., & Muennighoff, N.** (2023). C-Pack: Packaged Resources To Advance General Chinese Embedding (BGE / FlagEmbedding). arXiv:2309.07597.
- [19] **Liu, Z., Shao, S., Shi, X., Lian, D., & Xiao, S.** (2022). RetroMAE: Pre-Training Retrieval-oriented Language Models Via Masked Auto-Encoder. *EMNLP 2022*. arXiv:2205.12035.

C.5 BERT-style 专业领域模型 (§6 引用) (共 4 条 · §6 独立方法学章使用的探针模型原论文)

- [20] **Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K.** (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *NAACL 2019*, pp. 4171-4186. arXiv:1810.04805.
- [21] **Chalkidis, I., Fergadiotis, M., Malakasiotis, P., Aletras, N., & Androutsopoulos, I.** (2020). LEGAL-BERT: The Muppets straight out of Law School. *Findings of EMNLP 2020*. arXiv:2010.02559.
- [22] **Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., & Kang, J.** (2020). BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4): 1234-1240. arXiv:1901.08746.
- [23] **Gu, Y., Tinn, R., Cheng, H., Lucas, M., Usuyama, N., Liu, X., Naumann, T., Gao, J., & Poon, H.** (2021). Domain-Specific Language Model Pretraining for Biomedical Natural Language Processing (PubMedBERT). *ACM Transactions on Computing for Healthcare*, 3(1): 1-23. arXiv:2007.15779.

C.6 NPM 框架自身 (共 2 条 · 已在 Zenodo 发布的 NPM 系列前作)

- [24] **Ding, T.** (2026). Neural Percolation Model: A Porous-Media-Inspired Framework for Neural Network Training Dynamics. Zenodo. DOI: 10.5281/zenodo.19209722.
- [25] **Ding, T.** (2026). Cross-Family Convergence of Neural Network Weight Skeletons (NPM-K). Zenodo. DOI: 10.5281/zenodo.19652706.

附录 D · 代码与数据可用性

本研究的全部代码、数据和透明数据 reference 文档已在 GitHub 公开:

Code & data: <https://github.com/tiexinding/data-quality-vec-public>

仓库内容: 中英双版技术报告 v2.4 + 主线/探针/消融/5 处理共 19 份 CSV/JSON 数据 + F1-F4 主图 (中英 PNG+PDF 16 份) + 主管道脚本 (run_stage1_sbar_v2.py) + SVD 各向异性诊断 + K-scan + 图生成 + PDF 构建脚本. License: MIT.

中间 embedding (.npy, ~380 MB) 与 text cache (~137 MB) 不入仓, 可由 code/run_stage1_sbar_v2.py 从 monology/pile-uncopyrighted (HuggingFace) + 各模型 checkpoint 重新生成.